第20题 • 数据合入与完整评测

2026-10-29 | 所有成本均含实际决策耗时

已新增1128份样例到datasets/liunianwww，保留cyanneko原有80份输入及其元数据、VERSION。数据已推送，随后先推送当前源码，再运行合并后的完整eval。

集合	原有cyanneko	新增liunianwww	合计
train	40	600	640
eval	40	528	568
全部输入	80	1128	1208

新增eval由150份历史调参验证和378份冻结模型后生成的样例组成。它们现已评分并公开，均属于开发/回归数据，不能再称未来未见盲测。训练样例不进入此次568例正式开发评测。

校验与隔离

输入范围、每算子一次SWITCH、阶段顺序、声明计数、key%P映射、单分区累计大小不超过M、升序算子头，以及可核对的元数据均已检查。跨train/eval的原始操作流和规范化分区操作流交集为0。

新增输入约104.35 MB，最大单文件1,262,748字节。全库train/eval分别有620/564种规范化操作流；部分案例共享操作流但成本参数不同，案例数不等于独立流数。

新增输入中1094例的全局正分区大小比≥2，34例明确标为近均匀诊断。阈值2是本项目标签，非官方定义；诊断输入不充当满足定性偏斜或代表官方隐藏分布的证据。

版本绑定

数据提交：0be508208700edae7a7b4443b122c633cc87b0e0
测量前源码提交：149a91a7dda8ad5c03c360af1d3658bd3cc1d93b
cyanneko eval版本0.5.0；liunianwww eval版本0.1.0

完整Score：相比官方Naive下降多少

方案	总Score / 10^12 us	相对配对Naive下降
官方Naive（网络配对）	74.107525	0%
旧版主方案	55.159208	25.57%
8专家神经网络	54.856425	25.98%

计算口径：对每例3次重复取算术均值，再对568例求和。降幅=100×(1　候选总Score/配对Naive总Score)。Score=I/O时间+真实miss惩罚×miss次数+框架测得的决策时间。

网络总Score相对本次旧版总Score低约0.55%。每个候选均与自己的Naive配对运行；两批Naive的CPU存在测量波动，完整数值保留，不混用一批分母。

成员 / eval例数	网络相对Naive下降	旧版相对Naive下降
cyanneko / 40	60.06%	57.84%
liunianwww / 528	25.78%	25.39%

总成本比与逐例平均不同

上述25.98%是总成本降幅，I/O很大的样例权重更高，不能解释成每例平均都降低25.98%。逐例Score与D倍率的mean/P50/P90/worst、全部案例及家族分组另存JSON表；应结合退化情况判断。

网络 / Naive逐例倍率	mean	P50	P90	worst
Score	0.789634	0.963651	1.040246	2.615132
决策时间D	1.966149	1.573045	3.576098	14.373056

每例先取3次均值再计算倍率；568例等权，P50为普通中位数，P90为最近秩。网络404例降低、145例升高、19例平手，不能据总成本下降声称逐例都更优。总D之比0.801740也不等于逐例D倍率均值1.966149。

公共runner为schema 3，默认自动发现全部非空成员，partial=false；两种候选使用相同suite_id。封顶归一化分数会丢失差异，因此本报告不以封顶分作为优化结论。

本次没有根据合并评测重新训练、修改权重或重选策略。结果是本地合成开发集合表现，不是官方隐藏测试或通用最优证明。

复现、动作核查与证据

冻结与评测环境

模型为32→16→8、664参数，权重内嵌C++14；调度器推理1线程、纯CPU，不依赖GPU。公开参考引擎仅替换调度器实例，保留动作、状态和计时逻辑。基线为该引擎的NaiveSpillScheduler。

编译器：g++ 13.3.0；参数：-std=c++14 -O2 -Wall -Wextra -pedantic-errors。实际二进制、源码和公共runner的SHA绑定在证据中；程序的进程wall时间不替代Total_Decision_Time。

每种候选568例×3次，加同次数配对Naive；两种候选合计6816次运行，全部complete。任何失败都会使公共报告无有效汇总，本次没有删掉失败后只计算成功案例。

动作正确性另行核对

此前已独立核查的536个eval输入使用同一冻结网络源码。本次另对最新数据分支增加的32个eval执行动作/容量核算，I/O、hit、miss与当前SDK结果一致，合计覆盖568个eval；没有用程序正常退出冒充动作合法性证明。

发布与复现入口

数据：datasets分支的datasets/liunianwww/。代码与报告：source/liunianwww分支的design/。旧成员输入及元数据未修改；生成数据仅发布到数据分支。

先用design/tools/run.py分别构建neural、recommended、baseline；再用datasets分支当前evaluation/evaluate.py运行，默认自动发现成员，--repeats 3，基线命令明确指定官方Naive。测试报告的协议、suite_id、版本和程序身份须相同后再比较。

集合指纹

suite_id:
5e49bfe12077a229b8099c86bb8f67d3ba78491058d54a98b71d03acde5dea86

完整逐次测量、逐例表、家族与成员汇总、输入审计和新增32例动作核查分别保留。公开证据删除本机绝对路径，保留程序与数据哈希、重复次数和原始数值。