第20题 • 动态落盘调度

8种专家策略与微型神经网络选择器

方案实现、学术依据与最终本地验证 | 2026-10-29

已实现：从当前可见状态和自身历史提取32维特征，由32→16→8网络输出策略编号，再运行对应专家生成SPILL / LOAD动作。默认构造函数直接启用网络，权重内嵌单个C++14文件。

项目	当前交付
网络规模	664个float32参数；权重2656字节；约640次乘加
训练输入	600个本地输入 + GitHub datasets分支8个train输入
交付模型训练状态	15,255条；另有3,889条验证状态
最终Score验证	150例调参集、378例新测试、8例GitHub回归、6例规模测试
冻结后新测试比值	377个非零基线例几何均值0.975361；最差2.241042
版本定位	本地验证完成；神经网络为候选，旧版继续默认

运行流程

实际需要选择落盘策略 → 汇总可见特征 → 微型网络输出ID 0..7 → 执行一个专家 → 公共容量与next_op处理 → 返回合法动作 → 更新可见历史。

网络替代了顶层策略选择；专家内部仍采用可解释的规则或精确子问题算法。全局候选覆盖所有算子的驻留分区，支持跨算子落盘。

结论先行

新测试上Score几何均值约下降2.46%，GitHub回归集和规模诊断上则分别升高约5.68%与1.29%。网络增加回调成本，收益依赖负载。本轮完成所列本地测试并交付候选，继续保留旧版为默认。

02 / 候选策略：容量与复用

筛选目标是互补性与部署成本。初步在128个训练输入上运行各固定专家，随后比较选择器与旧版、强单专家。某专家在某类负载有效，不代表它在所有输入上都“较好”。

ID / 方法	做法与适用情形	依据与边界
0 最大分区优先	从所有算子候选中优先落盘大分区，快速释放内存；BUILD可作为低成本起点。	Velox官方实现思想[1]；可能牺牲热点，不保证Score最优。
1 小规模最小写出覆盖	候选数≤10时枚举子集，选择满足缺口且总字节最小者；更大时回退启发式。	容量覆盖子问题精确算法；交付版O(2^n)，最多1023个非空子集。
2 观测最近访问	优先驱逐已观测访问时间较早的分区，捕获时间局部性。	LRU思想适配；题目没有逐次hit回调，故不是完整LRU。
3 观测热度密度	按(1+衰减热度)/字节保留价值；对下一PROBE施加保护因子。	借鉴LFU/size及LHD单位空间价值[2]；未实现原LHD概率模型。

缺口的精确定义

可用空间F=M-U。当前需求d：INSERT溢出时为新增元组字节；PROBE miss时为目标分区全量字节；联合加载规划时为两分区之和。需要释放的缺口D=max(0,d-F)。候选排除当前INSERT目标等不可驱逐项。

ID 1 能证明什么

令候选大小为s_i，选择$x_i\in\{0,1\}$，最小化$\Sigma s_i \cdot x_i$，约束$\Sigma s_i \cdot x_i \geq D$。写带宽W固定且每次落盘按字节收费，因此此目标等价于立即写时间最小。枚举所有可行子集并取最小值，保证这个规划子问题精确。

例如F=8 MiB、待载入20 MiB，D=12 MiB；候选大小13、20、40 MiB，则立即写出最优是13 MiB。如果13 MiB分区马上被访问，未来总代价仍可能更高。公共next_op保护也可能改变最终动作，因此这里没有完整Score最优保证。

03 / 候选策略：成本与算子竞争

ID / 方法	实现	依据与边界
4 预计恢复代价密度	按[s/W+q·(s/R+32)]/s排序，低价值优先写出；已知下一PROBE时q=1。	代价感知缓存启发式；q由热度构造，32是固定尺度，均不是题面真实p。
5 观测版GreedyDual-Size	维护通胀L与H=L+c/s，驱逐低H；c取读写时间加固定尺度。	Cao、Irani的GDS[3]；只在可观测事件更新，原竞争界不直接适用。
6 阶段 + 算子软配额	根据算子阶段和压力分配软配额，BUILD用大小优先，PROBE用配额修正成本密度。	借鉴DuckDB并发算子动态内存管理[4]；未引入题面不允许的压缩或重分区。
7 前版自适应控制器	综合观测时间、热度、代价密度，通过ghost反馈切换；保留软配额及保守next_op。	项目此前主方案；反馈思想参考LeCaR[5]，不是原LeCaR实现。

next_op与跨算子动作

网络使用题面公开的一步next_op作为特征。专家共用下一目标保护、无额外落盘的预取，以及受限制的两分区联合规划。miss回调最后仍加载当前目标；不能据此访问更长未来。

数学论文的结论必须满足假设

原GDS用H=L+c/s整合访问新近性与取回代价[3]。本题的BUILD会改变分区大小，驱逐也收费，而且没有完整hit事件；这些条件改变了原问题。交付代码因此称“观测版”，不套用原论文竞争比。

切换时的历史处理

8个专家共享实际发生的观测、ghost反馈和GDS状态。运行时没有维护8份独立缓存，也没有先跑完8种策略再投票。选中策略可以直接使用共同历史；这是一套适配后的策略组合，而非8个原算法的独立复制。

04 / 分类网络与在线耗时

z=W2 • ReLU(W1 • x+b1)+b2；输出argmax(z)。部署只做两层矩阵向量乘加、ReLU和最大值比较，省去softmax，不调用Python或机器学习运行时。

特征范围	内容
0..7 容量与请求	已用/需求/缺口/空闲比例；算子数、分区数；BUILD请求与请求算子阶段
8..16 驻留结构	驻留比例，最大/最小/平均大小，大小集中度，BUILD/PROBE及请求算子占用
17..24 一步信息与I/O	next_op类型、分区大小与驻留、是否同算子、两目标能否共存；读写带宽
25..31 自身观测	累计/近期miss压力、目标/整体热度、快速回访压力、上次专家ID、平均分区大小

特征只依赖公开SystemState、一个next_op及自己记录的历史。真实p、总N、周期B、完整未来、文件名、样例种子都不进入模型。输入有部分可观测性：相同特征可能对应不同最优策略，不能期待零分类误差。

何时重新决策

每次溢出和首次miss回调都重新选择专家；周期回调若发现下一INSERT将溢出，也重新选择。无需选盘的空回调及简单可行预取走固定处理路径，避免没有必要的网络运行。当前网络权重离线固定，状态与部分专家反馈在运行中动态更新。

成本不仅是640次乘加

32维特征提取需要扫描候选状态，复杂度O(Q)，Q≤512；后续规划还有遍历、排序或小规模枚举。官方计时还包含状态快照等调用成本。因此评测记录Total_Decision_Time，不能用网络理论运算量代替实际回调延迟。

稳健偏置

在验证集上比较隐藏层8/16、旧策略ID 7输出偏置0/0.5，选中16与0.5。偏置给旧策略略高优先级，减少激进切换；它不是校准过的置信度，也不是最坏情况安全保证。

05 / 训练标签、数据划分与第二轮训练

离线反事实标签

在采样决策点复制相同模拟状态，让8个专家分别执行首个动作，然后用共同续行策略推进。比较 C_e=ΔIO_e+p • Δmiss_e+Δdecision_e。当前已发生的miss罚分是共同常数，不影响该点的候选比较。

默认向后观察384步；BUILD窗口可延伸至当前算子SWITCH之后128步，但最多2048步。未来仅供离线教师打标签。CPU标签是真实测量，带噪声；有限窗口与续行策略也有偏差，不能称为全局最优oracle。首个选策的共同推理开销未由固定专家标签完整刻画，最终仍须SDK全程评分。

软标签与成本敏感学习

设C*=min C_e，温度τ=max(1,0.02 • max(C*,1))；软标签t_e正比于exp(-clip((C_e-C*)/τ,0,20))。近乎平手的专家都获得权重，避免把CPU微小抖动当成绝对正确类别。优化软交叉熵加0.05倍期望截断遗憾项，按工作负载平衡样本权重。

训练为NumPy实现的Adam，160轮；按验证集截断成本遗憾选checkpoint，再用完整SDK Score选择网络大小及偏置。训练随机种子用于复现，不代表测试空间只有这些种子。

分组	输入数 / 状态数	用途
本地 + GitHub train	600+8 / 15,255	交付模型；GitHub贡献196条状态
本地验证	150 / 3,889	选checkpoint、隐藏层及偏置；不是最终盲测
GitHub eval	8 / 未用于训练	开发回归评分已完成；有历史使用暴露
第二轮追加	同一训练输入 / 10,575	网络轨迹重采样；合计25,830条，GitHub合计334条

按规范化操作流分组，同一流的不同成本配置不能跨训练与验证。GitHub版本固定为96f3e2da7954756d9346b4c45d375c018792530c。源仓库明确说明16例均参与过历史开发；此处不把eval称为未见数据。

第二轮采用DAgger式数据聚合思路[6]，收集初版网络实际遇到的状态。完整验证Score比值为0.961323、最差1.605629，未优于首轮，因此未采用。最终首轮权重结合O(2^n)枚举复核为0.952349；两轮教师的CPU标签实现版本存在区别。

06 / 已完成实验：收益与反例

公开参考引擎仅替换调度器，保留执行和计时。按例交替运行顺序，每配置3次；逐例取Score中位数，再计算相对旧版比值的几何均值。此均值是本地指标，不冒充官方跨例汇总公式。

最终源码测试集	Score比值几何均值	最差比值
调参验证150例	0.952349	1.473824
冻结后新测试378例	0.975361	2.241042
GitHub回归8例	1.056779	1.281646
规模诊断6例	1.012914	1.025815

新测试含20种基础负载、128个参数角点和专项场景；10个与开发数据操作流重复的模板被剔除后保留378例。其中1例基线Score为0，377例参与比值。新测试在冻结模型后生成，未再调参；它仍来自自建生成器，不能代表官方全部分布。

同批固定专家4	几何均值	最差比值
调参验证150例	0.952598	12.606436
新测试377个非零基线例	0.994863	7858.035861
GitHub回归8例	0.910727	5.252595
规模诊断6例	0.943746	1.070063

网络与固定专家4在验证均值上接近，新测试中网络尾部退化较小；GitHub及规模诊断的均值则由固定专家4更好。原始无偏置网络曾退化至38.31倍，已保留实验记录。没有一种方法在所有集合上都优胜。

回调时间中位数之和 / us	旧版	网络
调参验证150例	33,270.01	44,692.34
新测试非零基线例	233,970.11	271,365.87
规模诊断6例	4,768,257.50	5,615,801.25

最终四组测试共6,054条SDK运行记录。CPU是完整回调耗时，包含状态获取、特征汇总、网络与专家规划；不同批次CPU不可直接归因于单项优化。没有官方隐藏成绩或全输入最优保证。

07 / 本项目的贡献与下一步优先级

1. 面向本题完整Score的专家标签

贡献在于把跨算子落盘、未来恢复、miss罚分与实际CPU成本放进同一个有限窗口比较过程。首个动作由专家决定，后续用共同策略；比仅以当下释放字节标注更贴近本题。成本敏感学习本身是已有方法，本项目贡献是具体的可复现标签协议及部署适配。

2. 部分可见状态下的共享历史选择器

明确区分“观察到的热度”和真实全访问热度，使用合法的next_op；共享反馈历史，保持每次只执行一个专家。不同算子的候选进入同一规划过程，将阶段、内存竞争和选择器状态纳入分类。实现是工程与问题适配贡献，未宣称新通用学习理论。

3. 可证明的局部算法与廉价启发式共存

小候选集保留精确容量覆盖，大候选集使用有界成本启发式；模型学习何时值得支付精确计算成本。即使专家1的子问题精确，神经网络选择和完整Score仍没有同样保证。这一“局部保证 + 实测选策”的边界在实现与说明中保持一致。

4. 用实际运行状态反过来扩充训练集

神经网络动作会改变未来驻留与miss分布，单轮固定教师状态可能失配。第二轮收集模型自己的状态再训练，思想借鉴DAgger[6]；完整评分已完成，本次未改善验证表现，因此保留首轮权重。

下一步按收益优先，而非盲目加深网络

本轮已完成冻结后新样例、强单专家、最大规模与独立动作核算。后续研究可针对高损失误选增加风险权重，并验证便宜门控或特征增量维护是否值得；这些新增改进未包含在当前交付中。

极小网络是合理方向，但决定收益的是专家互补性、标签质量、可观测信息以及总代价。现有证据支持交付可研究的候选，不支持承诺最优或任何分布都下降。

08 / 复现入口与参考资料

项目入口

交付：design/MySpillScheduler_neural.cpp。训练与证据：design/neural_selector/。已有旧版推荐仍由CURRENT_SOLUTION.txt指示。全部算法均定义MySpillScheduler，每次只选择一个接入公开框架。

运行：python design/tools/run.py --policy neural --input 输入文件
核对：python design/neural_selector/verify.py
训练：python design/neural_selector/train.py fit
导出：python design/neural_selector/deploy.py model_16.json 0.5

离线训练依赖Python与NumPy；正式提交仅依赖C++14标准库。提供冻结的特征标签包、模型JSON、导出模板、离线教师、输入来源哈希和SDK运行记录。原始截图、网页缓存、编译产物和批量输入不纳入此次源码交付。

主要原始资料

[1] Velox官方文档：Spilling。最大分区选择与分区落盘。 [原始资料]

[2] Beckmann, Chen, Cidon. LHD: Improving Cache Hit Rate by Maximizing Hit Density. NSDI 2018. [原始资料]

[3] Cao, Irani. Cost-Aware WWW Proxy Caching Algorithms. USITS 1997. GreedyDual-Size算法原文。 [原始资料]

[4] Kuiper, Groß, Boncz, Mühleisen. Saving Private Hash Join. PVLDB 18(8):2748-2760, 2025. [原始资料]

[5] Vietri et al. Driving Cache Replacement with ML-based LeCaR. HotStorage 2018. [原始资料]

[6] Ross, Gordon, Bagnell. A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning. AISTATS 2011. [原始资料]

[7] 项目datasets分支：cyanneko共享数据及其历史开发使用说明。 [原始资料]

论文给出的方法与实验结论属于其原始环境。本报告引用其思想和公式，未将原论文收益或理论保证转写成本题保证。未完成的实验均明确标注。

09 / 完整性核查与最终版本

动作合法性独立核算

最终网络在1,150个输入上通过独立模拟器：608个训练、150个验证、8个GitHub回归、378个新测试与6个规模诊断。核查每步动作的分区编号、INSERT目标排除、LOAD状态及PROBE阶段、miss最后加载当前目标、逐动作容量，以及周期与结束时的内存账目。

其中542个已测SDK输入的I/O、hit、miss与独立核算一致。8个固定专家分别在150个验证输入上通过同样检查；固定专家7的I/O与miss与旧版匹配。公开框架正常退出不单独充当合法性证明。

枚举提速与部署一致性

子集和由逐掩码重扫改为递推，复杂度从O(n • 2^n)降为O(2^n)。3,000组随机小实例与完整枚举一致；150个验证输入的动作哈希与首轮源码一致。最终源码已重新全程评分，未把两批CPU差直接当成优化收益。

统一使用deploy.py导出权重。verify.py已确认模型+模板导出与实际评分源码字节一致，核对特征包哈希、分组隔离及6,054条SDK记录的Score算术。新测试可从记录的熵和生成器重建，378个输入哈希已逐一再现。

复现命令

```
python design/neural_selector/replay_fresh.py
python design/neural_selector/verify.py
python design/neural_selector/benchmark.py --manifest design/neural_selector/fresh_manifest.json --output
design/neural_selector/results/replay.json
```

最终提交判断

最终候选仍是32→16→8首轮权重、旧策略偏置0.5，结合等价枚举提速；第二轮模型未采用。神经网络在新测试平均有收益，但回归与规模诊断存在退化，所以CURRENT_SOLUTION继续推荐旧版，神经网络作为明确标注的可用候选。

此结论依据已完成的本地实验；不存在待批准的本轮测试，也不包含官方隐藏测试成绩。源码、训练特征包、证据、PDF与复现入口归入关键项目文件，原始截图和批量输入保留本地。